Documentação UD em português (e para língua portuguesa)

Elvis de Souza PUC-Rio, Brasil

Tatiana Cavalcanti

Aline Silveira

Wograine Evelyn

Cláudia Freitas

O projeto Universal Dependencies (mcdonald2013universal) apresenta um tagset e uma gramática. Isso significa dizer que, para além de um conjunto de etiquetas que correspondem às classes da Gramática Tradicional (objeto, sujeito etc.), o UD também faz diversas escolhas que diferem da GT. Nesse documento, apresentamos a documentação detalhadas e as escolhas linguísticas relativas ao processo de revisão do material UD em Português. Considerando que UD funciona como uma espécie de segunda língua gramatical, partimos, sempre que possível, das categorias e análises de GT, e não de UD. Os exemplos de frases e as listas foram retirados do corpus Bosque-UD (rademaker2017universal) versão 2.5.

Conteúdo

D	ocum	entação	o UD em português	
	(e p	ara lín	gua portuguesa)	
	Elv	is de So	ouza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn,	
	Clá	udia Fre	eitas	1
2	For	mato U	TD	5
	1	Colu	nas/anotações	5
	2	Mani	pulação em Python	6
3	Cla	sses gra	amaticais (upos)	7
	1	Verbo	os auxiliares	7
		1.1	Verbos de ligação	8
		1.2	Verbo ser como voz passiva	10
		1.3	Locuções verbais de tempo composto	10
		1.4	Locuções verbais aspectuais/modais	10
		1.5	Isso <i>foi</i> nos Estados Unidos: verbo <i>ser</i> como verbo pleno (<i>VERB</i>)	12
		1.6	Não são locuções verbais (VERB + VERB)	14
	2	Num		20
		2.1		20
		2.2		20
4	Atr	ibutos 1	morfológicos (feats)	23
5	Dep	oendên	cias (dephead e deprel)	27
	1	Estru	turas comparativas	27
		1.1	Frases do Working Group	27
		1 2	Fraces do Rosque-LID	27

2 Formato UD

Ir para tabela de conteúdos

Os treebanks adaptados para a gramática UD são disponibilizados no formato CoNLL, em que há um token por linha. Cada anotação de cada token, por sua vez, é disposta em uma coluna, sendo 10 colunas ao todo. Cada token tem a configuração conforme a Tabela 1: Colunas do formato UD 2.0, com uma tabulação (*Tab*) separando as colunas. Colunas sem nenhum valor devem, necessariamente, ser preenchidas com *underline*.

Tabela 1: Colunas do formato UD 2.0

id word lemma upos xpos feats dephead deprel deps misc

1 Colunas/anotações

- 1. "id" corresponde ao número do token, em ordem crescente;
- 2. "word", à palavra tal como aparece na frase (exceto no caso de contração, como "da", em que a palavra será desmembrada nos tokens "de" e "a");
- 3. "lemma" se refere à palavra tal como aparece no dicionário: em no singular e em masculino ou infinitivo;
- 4. "upos" (classe gramatical "universal") se refere à classe gramatical;
- 5. No corpus Bosque-UD, a coluna "xpos" (classe gramatical específica) é preenchida com a saída do sistema PALAVRAS para a mesma frase;
- 6. "feats" (atributos morfológicos) é preenchida com as características morfológicas do token:
- 7. "dephead" (dependência sintática), com o id do token de quem é filho;

- 8. "deprel" (relação de dependência), com a relação sintática que o conecta ao seu pai;
- 9. "deps" (dependência específica) não é utilizado no Bosque-UD;
- 10. "misc" (miscelânea) se refere a quaisquer informações extras que desejemos adicionar ao token.

2 Manipulação em Python

Para manipular arquivos no formato UD em Python, com as classes Corpus, Sentence e Token (e suas respectivas anotações), desenvolvemos e utilizamos o estrutura_ud.py.

3 Classes gramaticais (upos)

Ir para tabela de conteúdos

Tabela 2: As classes gramaticais do UD em português

Tabela 2: As classes gramaticais do UD em português

upos	Observações
ADJ	adjetivos e numerais ordinais
ADP	preposições
PUNCT	pontuação
ADV	advérbio
AUX	Seção 1: Verbos auxiliares
SYM	símbolos
INTJ	interjeição
CCONJ	conjunção coordenativa
NOUN	substantivo
DET	determinante - artigos e pronomes adjetivos
PROPN	nomes próprios, apenas se com inicial maiúscula
NUM	numeral - exceto os ordinais, que são adjetivos
PART	partícula
VERB	verbo
PRON	apenas pronomes substantivos
SCONJ	conjunções subordinativas
X	no Bosque-UD, palavras estrangeiras

1 Verbos auxiliares

Verbos auxiliares são classificados como *AUX*. O que conta como um verbo auxiliar é alvo de discussão nas gramáticas do português (elvis2019locverbal). De modo geral, classificamos como verbos auxiliares os verbos de ligação (Subseção 1.1: Verbos de ligação), o verbo auxiliar na voz passiva (Subseção 1.2: Verbo *ser* como

voz passiva), as locuções de tempo composto (Subseção 1.3: Locuções verbais de tempo composto), e as locuções verbais aspectuais e modais (Subseção 1.4: Locuções verbais aspectuais/modais).

Via de regra, verbos auxiliares (AUX) não podem ter dependentes, e dependem de um verbo principal (VERB). O deprel pode ser cop, aux ou aux:pass, de acordo com a função sintática.

Tabela 3: Lista das 23 palavras que ocorrem 3541 vezes como verbo auxiliar (AUX) no Bosque-UD

Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação (AUX/cop) no Bosque-UD

Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva (AUX/aux:pass) no Bosque-UD

Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal (AUX/aux) no Bosque-UD

Tabela 7: Lista das 31 MWEs que ocorrem 570 vezes como locuções auxiliares (*AUX/aux + ADP/compound*) no Bosque-UD

1.1 Verbos de ligação

Apenas os verbos "ser" e "estar" são considerados verbos de ligação, e portanto serão sempre anotados como AUX. Os demais verbos que a GT costuma elencar como verbo de ligação (parecer, permanecer, etc.) são anotados como VERB. Os verbos de ligação AUX terão relação sintática cop, e nunca poderão ser núcleo de uma oração (Xx) nem conter dependentes.

Figura 1: O preço \acute{e} de US\$ 422

Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação (AUX/cop) no Bosque-UD




Figura 1: O preço \acute{e} de US\$ 422

Tabela 3: Lista das 23 palavras que ocorrem 3541 vezes como verbo auxiliar (AUX) no Bosque-UD

Verbo auxiliar	Frequência	
acabar	56	
andar	4	
chegar	19	
começar	62	
continuar	57	
costumar	10	
deixar	24	
dever	217	
estar	282	
faltar	1	
ficar	11	
haver	37	
ir	358	
parar	3	
parecer	17	
passar	39	
poder	394	
procurar	1	
quer	1	
ser	1304	
ter	536	
vir	68	
voltar	40	

Verbo auxiliar	Frequência
ser	1304
ter	536
poder	394
ir	358
estar	282
dever	217
vir	68
começar	62
continuar	57
acabar	56
voltar	40
passar	39
haver	37
deixar	24
chegar	19
parecer	17
ficar	11
costumar	10
andar	4
parar	3
faltar	1
procurar	1
quer	1

Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação (AUX/cop)no Bosque-UD

Verbo de ligação	Frequência
estar	33
ser	105

1.2 Verbo ser como voz passiva

A anotação de "ser" como voz passiva, além do upos *AUX*, deve receber deprel *aux:pass*.

Figura 2: A fotografia foi publicada na imprensa

Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva (AUX/aux:pass) no Bosque-UD




Figura 2: A fotografia foi publicada na imprensa

Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva (*AUX/aux:pass*) no Bosque-UD

Voz passiva	Frequência
ficar	1
ser	1114

1.3 Locuções verbais de tempo composto

Segundo as gramáticas, são locuções verbais de tempo composto aquelas que têm como verbo auxiliar "ter", "haver" e, para nós, também "ir".

Figura 3: A Prefeitura não havia retirado o golfinho

Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal (AUX/aux) no Bosque-UD

1.4 Locuções verbais aspectuais/modais

Confira um exemplo de locução verbal aspectual na Figura 5: O Tribunal vai começar a ouvir as testemunhas, e modal na Figura 4: A seleção deve contar hoje




Figura 3: A Prefeitura não havia retirado o golfinho

Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal (AUX/aux) no Bosque-UD

Locução verbal	Frequência
acabar	56
andar	4
chegar	19
começar	62
continuar	57
costumar	10
deixar	24
dever	217
estar	249
faltar	1
ficar	10
haver	37
ir	358
parar	3
parecer	17
passar	39
poder	394
procurar	1
quer	1
ser	53
ter	536
vir	68
voltar	40

Frequência
536
394
358
249
217
68
62
57
56
53
40
39
37
24
19
17
10
10
4
3
1
1
1

com Giovane.

Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal (AUX/aux) no Bosque-UD

Segundo as gramáticas, o que distingue a locução verbal aspectual da modal é que, na primeira, o verbo auxiliar caracteriza a temporalidade da ação do verbo principal, e na segunda, o verbo auxiliar caracteriza um julgamento do enunciador sobre a ação do verbo principal. Alguns gramáticos divergem sobre como a classificação se dá, portanto apenas herdamos, no Bosque-UD, o que já era a anotação originária do PALAVRAS (bick2000parsing), e resolvemos não modificá-la.

Repare que, nos casos de locução verbal aspectual, geralmente há uma partícula interveniente no meio da locução, como na Figura 5: O Tribunal vai começar a ouvir as testemunhas, em que há um "a" entre "começar" e "ouvir". Encaramos que estamos diante de um fenômeno de phrasal verb, uma MWE do tipo AUX, como sugerido em elvis2019locverbal. Na frase, vai ouvir é uma locução verbal de tempo composto (Subseção 1.3: Locuções verbais de tempo composto), e "começar a ouvir" é uma locução verbal aspectual, sendo "começar a" uma expressão multipalavra (MWE) do tipo auxiliar.

Tabela 7: Lista das 31 MWEs que ocorrem 570 vezes como locuções auxiliares (*AUX/aux + ADP/compound*) no Bosque-UD




Figura 4: A seleção deve contar hoje com Giovane

1.5 Isso foi nos Estados Unidos: verbo ser como verbo pleno (VERB)

Atenção para 2 casos em que o "ser" não é verbo auxiliar e deve ser verbo pleno (upos *VERB*).

1) Como na Figura 6: A expectativa *era* que chegasse a US\$7 milhões, o "ser" deve ser núcleo da oração caso o predicado seja uma outra oração (*ccomp*, *xcomp*).

Tabela 7: Lista das 31 MWEs que ocorrem 570 vezes como locuções auxiliares (AUX/aux + ADP/compound) no Bosque-UD

MWE auxiliar	Frequência
acabar de	11
acabar por	30
andar a	3
chegar a	22
começar a	58
começar por	6
continuar a	57
continuar por	1
deixar de	30
dever a	1
estar a	124
estar para	1
estar por	1
ficar a	4
ficar de	1
haver a	1
haver de	2
haver que	1
ir a	3
ir de	1
parar de	3
passar a	43
poder a	3
ser de	3
tender a	1
ter a	9
ter de	62
ter que	3
tornar a	1
vir a	42
voltar a	42

MWE auxiliar	Frequência
estar a	124
ter de	62
começar a	58
continuar a	57
passar a	43
vir a	42
voltar a	42
acabar por	30
deixar de	30
chegar a	22
acabar de	11
ter a	9
começar por	6
ficar a	4
andar a	3
ir a	3
parar de	3
poder a	3
ser de	3
ter que	3
haver de	2
continuar por	1
dever a	1
estar para	1
estar por	1
ficar de	1
haver a	1
haver que	1
ir de	1
tender a	1
tornar a	1




Figura 5: O Tribunal vai começar a ouvir as testemunhas




Figura 6: A expectativa era que chegasse a US\$7 milhões

2) "ser" verbo intransitivo (verbo pleno) também deve ter a anotação *VERB*, como na Figura 7: Isso *foi* nos Estados Unidos.

1.6 Não são locuções verbais (VERB + VERB)

Ainda segundo as decisões do PALAVRAS (bick2000parsing), há outras tantas colocações de dois verbos que não são locuções verbais. Portanto, são todos casos de verbos plenos, de upos *VERB*, em que o segundo verbo é dependente do primeiro, como oração substantiva objetiva reduzida de infinitivo (Xx).

Figura 8: Muitos pintores quiseram aprender a pintar com ele

Tabela 8: Lista dos 196 verbos plenos que ocorrem 1150 vezes como *pais* de uma colocação verbal no Bosque-UD

Primeiro verbo (ordem alfabética)	#	Primeiro verbo (ordem de frequência)	#
abster	2	querer	108
acabar	3	conseguir	83
aceder	1	tentar	64
aceitar	6	fazer	45
achar	5	pretender	39
aconselhar	5	permitir	37
acreditar	2	decidir	33
acusar	30	acusar	30
admitir	12	deixar	27
afirmar	13	procurar	21
aguentar	1	levar	20
ajudar	9	ver	19
alegar	3	dar	18
ambicionar	1	gostar	17
ameaçar	14	obrigar	17
andar	2	ser	17
anunciar	2	saber	16
aperceber	1	ameaçar	14
apetecer	1	precisar	14
aplicar	1	preferir	14
apostar	1	resolver	14
aprender	5	afirmar	13
apresentar	2	admitir	12
apressar	1	considerar	12
aprestar	1	encontrar	12
aproveitar	1	ter	12
arriscar	2	dizer	11
atender	1	destinar	10
atrever	1	limitar	10
autorizar	3	ajudar	9
avisar	1	ficar	9
bastar	3	preparar	9
caber	1	esperar	8

Elvis de Souza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn, Cláudia Freitas

cansar	1	pensar	8
cessar	1	comprometer	7
chamar	4	consistir	7
citar	1	continuar	7
começar	1	convidar	7
comprometer	7	recusar	7
concordar	3	aceitar	6
condenar	1	convencer	6
conduzir	1	estar	6
confidenciar	1	manter	6
confirmar	1	prometer	6
conseguir	83	achar	5
considerar	12	aconselhar	5
consistir	7	aprender	5
consultar	1	forçar	5
contar	1	mandar	5
continuar	7	parecer	5
contribuir	3	passar	5
convencer	6	propor	5
convencionar	1	tender	5
convidar	7	visar	5
credenciar	1	chamar	4
criticar	1	desejar	4
culpar	1	encarregar	4
dar	18	evitar	4
decidir	33	impedir	4
declarar	3	interessar	4
declinar	1	proibir	4
dedicar	2	reconhecer	4
deixar	27	sentir	4
depender	1	tencionar	4
desafiar	2	tratar	4
desejar	4	acabar	3
desistir	1	alegar	3
destinar	10	autorizar	3
dever	3	bastar	3

dispor	3	concordar	3
dizer	11	contribuir	3
duvidar	1	declarar	3
empenhar	2	dever	3
encarregar	4	dispor	3
encontrar	12	insistir	3
ensinar	1	ir	3
equivaler	1	optar	3
escolher	1	ousar	3
escusar	2	pôr	3
esperar	8	vir	3
estar	6	abster	2
estimar	1	acreditar	2
estimular	1	andar	2
estudar	1	anunciar	2
evitar	4	apresentar	2
exigir	1	arriscar	2
exortar	1	dedicar	2
experimentar	1	desafiar	2
falar	2	empenhar	2
fartar	1	escusar	2
fazer	45	falar	2
ficar	9	garantir	2
fingir	1	haver	2
foi	1	imaginar	2
forçar	5	impor	2
garantir	2	importar	2
gostar	17	incentivar	2
habituar	1	mostrar	2
haver	2	necessitar	2
imaginar	2	negar	2
impedir	4	ouvir	2
impor	2	parar	2
importar	2	queixar	2
incentivar	2	receber	2
incluir	1	referir	2

Elvis de Souza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn, Cláudia Freitas

indagar	1	resistir	2
influenciar	1	sentar	2
informar	1	tornar	2
insinuar	1	aceder	1
insistir	3	aguentar	1
instar	1	ambicionar	1
interessar	4	aperceber	1
ir	3	apetecer	1
lembrar	1	aplicar	1
levar	20	apostar	1
limitar	10	apressar	1
mandar	5	aprestar	1
manter	6	aproveitar	1
merecer	1	atender	1
mostrar	2	atrever	1
necessitar	2	avisar	1
negar	2	caber	1
obrigar	17	cansar	1
optar	3	cessar	1
orgulhar	1	citar	1
ousar	3	começar	1
ouvir	2	condenar	1
parar	2	conduzir	1
parecer	5	confidenciar	1
passado	1	confirmar	1
passar	5	consultar	1
pedir	1	contar	1
pensar	8	convencionar	1
perder	1	credenciar	1
permanecer	1	criticar	1
permitir	37	culpar	1
persuadir	1	declinar	1
planear	1	depender	1
poder	1	desistir	1
precisar	14	duvidar	1
preferir	14	ensinar	1

preparar	9	equivaler	1
pretender	39	escolher	1
prevenir	1	estimar	1
prever	1	estimular	1
procurar	21	estudar	1
proibir	4	exigir	1
projectar	1	exortar	1
prometer	6	experimentar	1
propiciar	1	fartar	1
propor	5	fingir	1
provocar	1	foi	1
pôr	3	habituar	1
queixar	2	incluir	1
querer	108	indagar	1
receber	2	influenciar	1
reclamar	1	informar	1
recomeçar	1	insinuar	1
recompensar	1	instar	1
reconhecer	4	lembrar	1
recordar	1	merecer	1
recusar	7	orgulhar	1
reduzir	1	passado	1
referir	2	pedir	1
resistir	2	perder	1
resolver	14	permanecer	1
respeitar	1	persuadir	1
restar	1	planear	1
retirar	1	poder	1
saber	16	prevenir	1
salientar	1	prever	1
sentar	2	projectar	1
sentir	4	propiciar	1
ser	17	provocar	1
soar	1	reclamar	1
sonhar	1	recomeçar	1
sublinhar	1	recompensar	1

sujeitar			
Sujcital	1	recordar	1
suportar	1	reduzir	1
surgir	1	respeitar	1
suspeitar	1	restar	1
tardar	1	retirar	1
teimar	1	salientar	1
temer	1	soar	1
tencionar	4	sonhar	1
tender	5	sublinhar	1
tentar	64	sujeitar	1
ter	12	suportar	1
tornar	2	surgir	1
tratar	4	suspeitar	1
trazer	1	tardar	1
ver	19	teimar	1
vir	3	temer	1
virar	1	trazer	1
visar	5	virar	1
voltar	1	voltar	1

Tabela 8: Lista dos 196 verbos plenos que ocorrem 1150 vezes como *pais* de uma colocação verbal no Bosque-UD

2 Numerais

2.1 title

2.2 Primeiro lugar: adjetivo ou numeral?

Numerais ordinais escritos por extenso devem ser anotados como *ADJ*, e recebem a feature *NumType=Ord*, como na Figura 9: Anotação do sintagma *primeira tentativa*.




Figura 7: Isso foi nos Estados Unidos




Figura 8: Muitos pintores quiseram aprender a pintar com ele




Figura 9: Anotação do sintagma primeira tentativa

4 Atributos morfológicos (feats)

Ir para tabela de conteúdos

Temos a seguinte distribuição de atributos morfológicos por classe gramatical (Tabela 9: Atributos morfológicos (feats)). É importante notar que os atributos morfológicos devem constar em ordem alfabética e são separados por uma barra reta.

upos	features
ADJ	Gender=[Fem, Masc, Unsp]
	NumType=[Ord]
	Number=[Plur, Sing]
ADP	_
ADV	Polarity=[Neg]
	_
AUX	Gender=[Fem, Masc] Mood=[Cnd, Imp, Ind, Sub] Number=[Plur, Sing] Person=[1, 2, 3] Tense=[Fut, Imp, Past, Pqp, Pres] VerbForm=[Fin, Ger, Inf, Part]
CCONJ	_
DET	Definite=[Def, Ind] Gender=[Fem, Masc, Unsp] Number=[Plur, Sing, Unsp] PronType=[Art, Dem, Emp, Ind, Int, Neg, Prs, Rel, Tot]

INTJ NOUN Foreign=[Yes] Gender=[Fem, Masc, Unsp] NumType=[Ord] Number=[Plur, Sing, Unsp] NUM Gender=[Fem, Masc, Unsp] NumType=[Card, Frac, Mult, Ord, Range, Sets] Number=[Plur, Sing] **PART** Gender=[Masc] Number=[Sing] PRON Case=[Acc, Dat, Nom] Definite=[Def, Ind] Gender=[Fem, Masc, Unsp] Number=[Plur, Sing, Unsp] Person=[1, 2, 3] PronType=[Art, Dem, Ind, Int, Neg, Prs, Rel, Tot] Reflex=[Yes] VerbForm=[Ger] **PROPN** Gender=[Fem, Masc, Unsp] Number=[Plur, Sing] **PUNCT SCONJ** Gender=[Fem, Masc] Number=[Plur, Sing] PronType=[Ind, Rel] SYM

Documentação UD em português (e para língua portuguesa)

5 Dependências (dephead e deprel)

Ir para tabela de conteúdos

1 Estruturas comparativas

Estruturas comparativas são de anotação complexa, o que se verifica pela existência de um working group (WG) em UD dedicado especialmente a elas. A seguir, listamos as frases utilizadas no WG, traduzidas em português, e com a anotação adequada, além de algumas frases de anotação complexa no Bosque-UD.

1.1 Frases do Working Group

Figura 10: Eu coloquei tanta farinha quanto a receita pedia

Figura 11: Martin é o cara mais inteligente de todos

1.2 Frases do Bosque-UD

Abreviações

Ir para tabela de conteúdos

Agradecimentos

Ir para tabela de conteúdos