Documentação UD em português (e para língua portuguesa)

Elvis de Souza PUC-Rio, Brasil

Tatiana Cavalcanti

Aline Silveira

Wograine Evelyn

Cláudia Freitas

O projeto Universal Dependencies (McDonald et al. 2013) apresenta um tagset e uma gramática. Isso significa dizer que, para além de um conjunto de etiquetas que correspondem às classes da Gramática Tradicional (objeto, sujeito etc.), o UD também faz diversas escolhas que diferem da GT. Nesse documento, apresentamos a documentação detalhadas e as escolhas linguísticas relativas ao processo de revisão do material UD em Português. Considerando que UD funciona como uma espécie de segunda língua gramatical, partimos, sempre que possível, das categorias e análises de GT, e não de UD. Os exemplos de frases e as listas foram retirados do corpus Bosque-UD (Rademaker et al. (2017)) versão 2.5.

Conteúdo

Do	ocum	ıentaçã	o UD em português	
	(e p	ara lín	gua portuguesa)	
	Elv	is de So	ouza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn,	
		udia Fr	·	1
2	For	mato U	JD	5
	1	Colu	nas/anotações	5
	2	Mani	ipulação em Python	6
3	Cla	sses gr	amaticais (upos)	7
	1	Verb	os auxiliares	7
		1.1	Verbos de ligação	8
		1.2	Verbo ser como voz passiva	8
		1.3	Locuções verbais de tempo composto	11
		1.4	Locuções verbais aspectuais/modais	11
		1.5	Isso <i>foi</i> nos Estados Unidos: verbo <i>ser</i> como verbo pleno (<i>VERB</i>)	12
		1.6	Não são locuções verbais: VERB + VERB	15
	2	Num	erais	21
		2.1	<i>Primeiro</i> lugar: adjetivo ou numeral?	21
4	Atr	ibutos	morfológicos (feats)	23
5	Dej	pendên	cias (dephead e deprel)	27
	1	Estru	ituras comparativas	27
		1.1	Frases do Working Group	27
		12	Frases do Bosque-UD	27

2 Formato UD

Ir para tabela de conteúdos

Os treebanks adaptados para a gramática UD são disponibilizados no formato CoNLL, em que há um token por linha. Cada anotação de cada token, por sua vez, é disposta em uma coluna, sendo 10 colunas ao todo. Cada token tem a configuração conforme a Tabela 1: Colunas do formato UD 2.0, com uma tabulação (*Tab*) separando as colunas. Colunas sem nenhum valor devem, necessariamente, ser preenchidas com *underline*.

Tabela 1: Colunas do formato UD 2.0

id word lemma upos xpos feats dephead deprel deps misc

1 Colunas/anotações

- 1. "id" corresponde ao número do token, em ordem crescente;
- 2. "word", à palavra tal como aparece na frase (exceto no caso de contração, como "da", em que a palavra será desmembrada nos tokens "de" e "a");
- 3. "lemma" se refere à palavra tal como aparece no dicionário: em no singular e em masculino ou infinitivo;
- 4. "upos" (classe gramatical "universal") se refere à classe gramatical;
- 5. No corpus Bosque-UD, a coluna "xpos" (classe gramatical específica) é preenchida com a saída do sistema PALAVRAS para a mesma frase;
- "feats" (atributos morfológicos) é preenchida com as características morfológicas do token;
- 7. "dephead" (dependência sintática), com o id do token de quem é filho;

- 8. "deprel" (relação de dependência), com a relação sintática que o conecta ao seu pai;
- 9. "deps" (dependência específica) não é utilizado no Bosque-UD;
- 10. "misc" (miscelânea) se refere a quaisquer informações extras que desejemos adicionar ao token.

2 Manipulação em Python

Para manipular arquivos no formato UD em Python, com as classes Corpus, Sentence e Token (e suas respectivas anotações), desenvolvemos e utilizamos o estrutura_ud.py.

3 Classes gramaticais (upos)

Ir para tabela de conteúdos

As classes gramaticais em UD podem ser consultadas na Tabela 2: As classes gramaticais do UD em português.

Tabela 2: As classes gramaticais do UD em português

upos	Observações
ADJ	adjetivos e numerais ordinais
ADP	preposições
PUNCT	pontuação
ADV	advérbio
AUX	Seção 1: Verbos auxiliares
SYM	símbolos
INTJ	interjeição
CCONJ	conjunção coordenativa
NOUN	substantivo
DET	determinante - artigos e pronomes adjetivos
PROPN	nomes próprios, apenas se com inicial maiúscula
NUM	numeral - exceto os ordinais, que são adjetivos
PART	partícula
VERB	verbo
PRON	apenas pronomes substantivos
SCONJ	conjunções subordinativas
X	no Bosque-UD, palavras estrangeiras

1 Verbos auxiliares

Verbos auxiliares são classificados como *AUX*. O que conta como um verbo auxiliar é alvo de discussão nas gramáticas do português (de Souza & Freitas (2019)).

De modo geral, classificamos como verbos auxiliares os verbos de ligação (Subseção 1.1: Verbos de ligação), o verbo auxiliar na voz passiva (Subseção 1.2: Verbo *ser* como voz passiva), as locuções de tempo composto (Subseção 1.3: Locuções verbais de tempo composto), e as locuções verbais aspectuais e modais (Subseção 1.4: Locuções verbais aspectuais/modais).

Via de regra, verbos auxiliares (*AUX*) não podem ter dependentes, e dependem de um verbo principal (*VERB*). O deprel pode ser *cop*, *aux* ou *aux:pass*, de acordo com a função sintática.

A Tabela 3: Lista das 23 palavras que ocorrem 3541 vezes como verbo auxiliar no Bosque-UD mostra a lista com todos os verbos auxiliares, sejam eles verbos de ligação, voz passiva ou locuções verbais de tempo composto/aspectuais/modais.

A Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação no Bosque-UD mostra a lista apenas com os verbos de ligação.

A Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva no Bosque-UD mostra a lista de todos os verbos que ocupam a posição de voz passiva.

A Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal no Bosque-UD mostra a lista de todos os verbos que são auxiliares em uma locução verbal.

1.1 Verbos de ligação

Apenas os verbos "ser" e "estar" são considerados verbos de ligação, e portanto serão sempre anotados como *AUX*. Os demais verbos que a GT costuma elencar como verbo de ligação (parecer, permanecer, etc.) são anotados como *VERB*. Os verbos de ligação *AUX* terão relação sintática *cop*, e nunca poderão ser núcleo de uma oração (Xx) nem conter dependentes. Figura 1: O preço é de US\$ 422.

A frequência dos verbos de ligação pode ser consultada em Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação no Bosque-UD.

1.2 Verbo ser como voz passiva

A anotação de "ser" como voz passiva, além do upos *AUX*, deve receber deprel *aux:pass*, como na Figura 2: A fotografia *foi* publicada na imprensa.

A frequência da voz passiva pode ser consultada em Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva no Bosque-UD.

Tabela 3: Lista das 23 palavras que ocorrem 3541 vezes como verbo auxiliar no Bosque-UD $\,$

Verbo auxiliar	Frequência
acabar	56
andar	4
chegar	19
começar	62
continuar	57
costumar	10
deixar	24
dever	217
estar	282
faltar	1
ficar	11
haver	37
ir	358
parar	3
parecer	17
passar	39
poder	394
procurar	1
quer	1
ser	1304
ter	536
vir	68
voltar	40

Verbo auxiliar	Frequência
ser	1304
ter	536
poder	394
ir	358
estar	282
dever	217
vir	68
começar	62
continuar	57
acabar	56
voltar	40
passar	39
haver	37
deixar	24
chegar	19
parecer	17
ficar	11
costumar	10
andar	4
parar	3
faltar	1
procurar	1
quer	1

Tabela 4: Lista das 2 palavras que ocorrem 138 vezes como verbo de ligação no Bosque-UD

Verbo de ligação	Frequência
estar	33
ser	105

Tabela 5: Lista das 2 palavras que ocorrem 1115 vezes como voz passiva no Bosque-UD

Voz passiva	Frequência
ficar	1
ser	1114

Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal no Bosque-UD $\,$

Locução verbal	Frequência
acabar	56
andar	4
chegar	19
começar	62
continuar	57
costumar	10
deixar	24
dever	217
estar	249
faltar	1
ficar	10
haver	37
ir	358
parar	3
parecer	17
passar	39
poder	394
procurar	1
quer	1
ser	53
ter	536
vir	68
voltar	40

Locução verbal	Frequência
ter	536
poder	394
ir	358
estar	249
dever	217
vir	68
começar	62
continuar	57
acabar	56
ser	53
voltar	40
passar	39
haver	37
deixar	24
chegar	19
parecer	17
costumar	10
ficar	10
andar	4
parar	3
faltar	1
procurar	1
quer	1

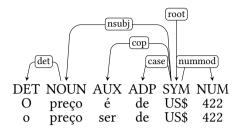


Figura 1: O preço é de US\$ 422

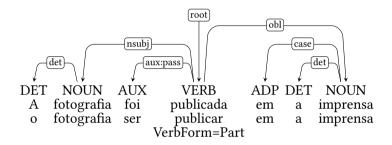


Figura 2: A fotografia foi publicada na imprensa

1.3 Locuções verbais de tempo composto

Segundo as gramáticas, são locuções verbais de tempo composto aquelas que têm como verbo auxiliar "ter", "haver" e, para nós, também "ir". Confira um exemplo de locução verbal de tempo composto na Figura 3: A Prefeitura não *havia retirado* o golfinho.

A Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal no Bosque-UD mostra a lista de locuções verbais, entre elas, as de tempo composto.

1.4 Locuções verbais aspectuais/modais

Confira um exemplo de locução verbal aspectual na Figura 5: O Tribunal vai começar a ouvir as testemunhas, e modal na Figura 4: A seleção deve contar hoje com Giovane.

A Tabela 6: Lista das 23 palavras que ocorrem 2256 vezes como locução verbal

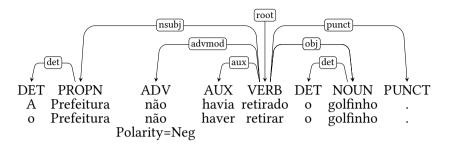


Figura 3: A Prefeitura não havia retirado o golfinho

no Bosque-UD mostra a lista de locuções verbais, entre elas, as locuções verbais aspectuais/modais.

Segundo as gramáticas, o que distingue a locução verbal aspectual da modal é que, na primeira, o verbo auxiliar caracteriza a temporalidade da ação do verbo principal, e na segunda, o verbo auxiliar caracteriza um julgamento do enunciador sobre a ação do verbo principal. Alguns gramáticos divergem sobre como a classificação se dá, portanto apenas herdamos, no Bosque-UD, o que já era a anotação originária do PALAVRAS (Bick 2000), e resolvemos não modificá-la.

Repare que, nos casos de locução verbal aspectual, geralmente há uma partícula interveniente no meio da locução, como na Figura 5: O Tribunal vai começar a ouvir as testemunhas, em que há um "a" entre "começar" e "ouvir". Encaramos que estamos diante de um fenômeno de *phrasal verb*, uma MWE do tipo *AUX*, como sugerido em de Souza & Freitas (2019). Na frase, vai ouvir é uma locução verbal de tempo composto (Subseção 1.3: Locuções verbais de tempo composto), e "começar a ouvir" é uma locução verbal aspectual, sendo "começar a" uma expressão multi-palavra (MWE) do tipo auxiliar.

Listamos essas MWEs auxiliares com partículas intervenientes na Tabela 7: Lista das 31 MWEs que ocorrem 570 vezes como locuções auxiliares no Bosque-UD.

1.5 Isso foi nos Estados Unidos: verbo ser como verbo pleno (VERB)

Atenção para 2 casos em que o "ser" não é verbo auxiliar e deve ser verbo pleno (upos *VERB*).

1) Como na Figura 6: A expectativa *era* que chegasse a US\$7 milhões, o "ser" deve ser núcleo da oração caso o predicado seja uma outra oração (*ccomp*, *xcomp*).

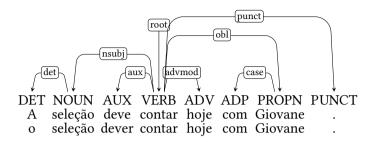


Figura 4: A seleção deve contar hoje com Giovane

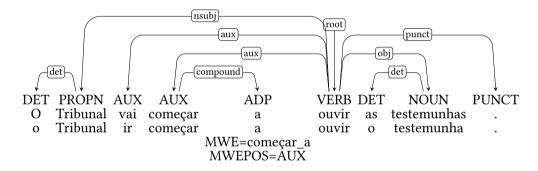


Figura 5: O Tribunal vai começar a ouvir as testemunhas

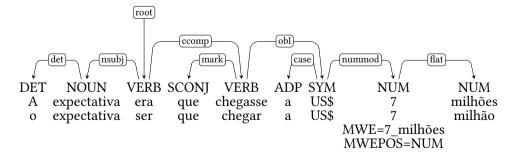


Figura 6: A expectativa era que chegasse a US\$7 milhões

Tabela 7: Lista das 31 MWEs que ocorrem 570 vezes como locuções auxiliares no Bosque-UD

MWE auxiliar	Frequência
acabar de	11
acabar por	30
andar a	3
chegar a	22
começar a	58
começar por	6
continuar a	57
continuar por	1
deixar de	30
dever a	1
estar a	124
estar para	1
estar por	1
ficar a	4
ficar de	1
haver a	1
haver de	2
haver que	1
ir a	3
ir de	1
parar de	3
passar a	43
poder a	3
ser de	3
tender a	1
ter a	9
ter de	62
ter que	3
tornar a	1
vir a	42
voltar a	42

MWE auxiliar	Frequência
estar a	124
ter de	62
começar a	58
continuar a	57
passar a	43
vir a	42
voltar a	42
acabar por	30
deixar de	30
chegar a	22
acabar de	11
ter a	9
começar por	6
ficar a	4
andar a	3
ir a	3
parar de	3
poder a	3
ser de	3
ter que	3
haver de	2
continuar por	1
dever a	1
estar para	1
estar por	1
ficar de	1
haver a	1
haver que	1
ir de	1
tender a	1
tornar a	1

2) "ser" verbo intransitivo (verbo pleno) também deve ter a anotação *VERB*, como na Figura 7: Isso *foi* nos Estados Unidos.

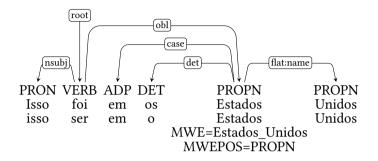


Figura 7: Isso foi nos Estados Unidos

1.6 Não são locuções verbais: VERB + VERB

Ainda segundo as decisões do PALAVRAS (Bick 2000), há outras tantas colocações de dois verbos que não são locuções verbais. Portanto, são todos casos de verbos plenos, de upos *VERB*, em que o segundo verbo é dependente do primeiro, como oração substantiva objetiva reduzida de infinitivo (Xx). Veja a lista de verbos na Tabela 8: Lista dos 196 verbos plenos que ocorrem 1150 vezes como *pais* de uma colocação verbal no Bosque-UD.

Primeiro verbo (ordem alfabética)	#	Primeiro verbo (ordem de frequên- cia)	#
abster	2	querer	108
acabar	3	conseguir	83
aceder	1	tentar	64
aceitar	6	fazer	45
achar	5	pretender	39
aconselhar	5	permitir	37
acreditar	2	decidir	33
acusar	30	acusar	30
admitir	12	deixar	27
afirmar	13	procurar	21

Elvis de Souza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn, Cláudia Freitas

ajudar 9 ver 19 alegar 3 dar 18 ambicionar 1 gostar 17 ameaçar 14 obrigar 17	
ambicionar1gostar17ameaçar14obrigar17	
ameaçar 14 obrigar 17	
1	
andar 2 ser 17	
anunciar 2 saber 16	
aperceber 1 ameaçar 14	
apetecer 1 precisar 14	
aplicar 1 preferir 14	
apostar 1 resolver 14	
aprender 5 afirmar 13	
apresentar 2 admitir 12	
apressar 1 considerar 12	
aprestar 1 encontrar 12	
aproveitar 1 ter 12	
arriscar 2 dizer 11	
atender 1 destinar 10	
atrever 1 limitar 10	
autorizar 3 ajudar 9	
avisar 1 ficar 9	
bastar 3 preparar 9	
caber 1 esperar 8	
cansar 1 pensar 8	
cessar 1 comprometer 7	
chamar 4 consistir 7	
citar 1 continuar 7	
começar 1 convidar 7	
comprometer 7 recusar 7	
concordar 3 aceitar 6	
condenar 1 convencer 6	
conduzir 1 estar 6	
confidenciar 1 manter 6	
confirmar 1 prometer 6	
conseguir 83 achar 5	
considerar 12 aconselhar 5	

consistir	7	aprender	5
consultar	1	forçar	5
contar	1	mandar	5
continuar	7	parecer	5
contribuir	3	passar	5
convencer	6	propor	5
convencionar	1	tender	5
convidar	7	visar	5
credenciar	1	chamar	4
criticar	1	desejar	4
culpar	1	encarregar	4
dar	18	evitar	4
decidir	33	impedir	4
declarar	3	interessar	4
declinar	1	proibir	4
dedicar	2	reconhecer	4
deixar	27	sentir	4
depender	1	tencionar	4
desafiar	2	tratar	4
desejar	4	acabar	3
desistir	1	alegar	3
destinar	10	autorizar	3
dever	3	bastar	3
dispor	3	concordar	3
dizer	11	contribuir	3
duvidar	1	declarar	3
empenhar	2	dever	3
encarregar	4	dispor	3
encontrar	12	insistir	3
ensinar	1	ir	3
equivaler	1	optar	3
escolher	1	ousar	3
escusar	2	pôr	3
esperar	8	vir	3
estar	6	abster	2
estimar	1	acreditar	2

Elvis de Souza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn, Cláudia Freitas

estimular	1	andar	2
estudar	1	anunciar	2
evitar	4	apresentar	2
exigir	1	arriscar	2
exortar	1	dedicar	2
experimentar	1	desafiar	2
falar	2	empenhar	2
fartar	1	escusar	2
fazer	45	falar	2
ficar	9	garantir	2
fingir	1	haver	2
foi	1	imaginar	2
forçar	5	impor	2
garantir	2	importar	2
gostar	17	incentivar	2
habituar	1	mostrar	2
haver	2	necessitar	2
imaginar	2	negar	2
impedir	4	ouvir	2
impor	2	parar	2
importar	2	queixar	2
incentivar	2	receber	2
incluir	1	referir	2
indagar	1	resistir	2
influenciar	1	sentar	2
informar	1	tornar	2
insinuar	1	aceder	1
insistir	3	aguentar	1
instar	1	ambicionar	1
interessar	4	aperceber	1
ir	3	apetecer	1
lembrar	1	aplicar	1
levar	20	apostar	1
limitar	10	apressar	1
mandar	5	aprestar	1
manter	6	aproveitar	1
	•	•	•

merecer	1	atender	1
mostrar	2	atrever	1
necessitar	2	avisar	1
negar	2	caber	1
obrigar	17	cansar	1
optar	3	cessar	1
orgulhar	1	citar	1
ousar	3	começar	1
ouvir	2	condenar	1
parar	2	conduzir	1
parecer	5	confidenciar	1
passado	1	confirmar	1
passar	5	consultar	1
pedir	1	contar	1
pensar	8	convencionar	1
perder	1	credenciar	1
permanecer	1	criticar	1
permitir	37	culpar	1
persuadir	1	declinar	1
planear	1	depender	1
poder	1	desistir	1
precisar	14	duvidar	1
preferir	14	ensinar	1
preparar	9	equivaler	1
pretender	39	escolher	1
prevenir	1	estimar	1
prever	1	estimular	1
procurar	21	estudar	1
proibir	4	exigir	1
projectar	1	exortar	1
prometer	6	experimentar	1
propiciar	1	fartar	1
propor	5	fingir	1
provocar	1	foi	1
pôr	3	habituar	1
queixar	2	incluir	1

Elvis de Souza, Tatiana Cavalcanti, Aline Silveira, Wograine Evelyn, Cláudia Freitas

querer	108	indagar	1
receber	2	influenciar	1
reclamar	1	informar	1
recomeçar	1	insinuar	1
recompensar	1	instar	1
reconhecer	4	lembrar	1
recordar	1	merecer	1
recusar	7	orgulhar	1
reduzir	1	passado	1
referir	2	pedir	1
resistir	2	perder	1
resolver	14	permanecer	1
respeitar	1	persuadir	1
restar	1	planear	1
retirar	1	poder	1
saber	16	prevenir	1
salientar	1	prever	1
sentar	2	projectar	1
sentir	4	propiciar	1
ser	17	provocar	1
soar	1	reclamar	1
sonhar	1	recomeçar	1
sublinhar	1	recompensar	1
sujeitar	1	recordar	1
suportar	1	reduzir	1
surgir	1	respeitar	1
suspeitar	1	restar	1
tardar	1	retirar	1
teimar	1	salientar	1
temer	1	soar	1
tencionar	4	sonhar	1
tender	5	sublinhar	1
tentar	64	sujeitar	1
ter	12	suportar	1
tornar	2	surgir	1
tratar	4	suspeitar	1
	•	•	*

trazer	1	tardar	1
ver	19	teimar	1
vir	3	temer	1
virar	1	trazer	1
visar	5	virar	1
voltar	1	voltar	1

Tabela 8: Lista dos 196 verbos plenos que ocorrem 1150 vezes como *pais* de uma colocação verbal no Bosque-UD

2 Numerais

2.1 Primeiro lugar: adjetivo ou numeral?

Numerais ordinais escritos por extenso devem ser anotados como $AD\mathcal{J}$, e recebem a feature NumType=Ord, como na Figura 8: Anotação do sintagma primeira tentativa.

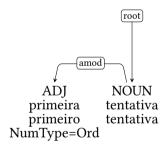


Figura 8: Anotação do sintagma primeira tentativa

4 Atributos morfológicos (feats)

Ir para tabela de conteúdos

Temos a seguinte distribuição de atributos morfológicos por classe gramatical (Tabela 9: Atributos morfológicos (feats)). É importante notar que os atributos morfológicos devem constar em ordem alfabética e são separados por uma barra reta.

upos	features
ADJ	Gender=[Fem, Masc, Unsp]
	NumType=[Ord]
	Number=[Plur, Sing]
ADP	_
ADV	Polarity=[Neg]
	_
AUX	Gender=[Fem, Masc] Mood=[Cnd, Imp, Ind, Sub] Number=[Plur, Sing] Person=[1, 2, 3] Tense=[Fut, Imp, Past, Pqp, Pres] VerbForm=[Fin, Ger, Inf, Part]
CCONJ	_
DET	Definite=[Def, Ind] Gender=[Fem, Masc, Unsp] Number=[Plur, Sing, Unsp] PronType=[Art, Dem, Emp, Ind, Int, Neg, Prs, Rel, Tot]

INTJ NOUN Foreign=[Yes] Gender=[Fem, Masc, Unsp] NumType=[Ord] Number=[Plur, Sing, Unsp] NUM Gender=[Fem, Masc, Unsp] NumType=[Card, Frac, Mult, Ord, Range, Sets] Number=[Plur, Sing] **PART** Gender=[Masc] Number=[Sing] PRON Case=[Acc, Dat, Nom] Definite=[Def, Ind] Gender=[Fem, Masc, Unsp] Number=[Plur, Sing, Unsp] Person=[1, 2, 3] PronType=[Art, Dem, Ind, Int, Neg, Prs, Rel, Tot] Reflex=[Yes] VerbForm=[Ger] **PROPN** Gender=[Fem, Masc, Unsp] Number=[Plur, Sing] **PUNCT SCONJ** Gender=[Fem, Masc] Number=[Plur, Sing] PronType=[Ind, Rel] SYM

Documentação UD em português (e para língua portuguesa)

5 Dependências (dephead e deprel)

Ir para tabela de conteúdos

1 Estruturas comparativas

Estruturas comparativas são de anotação complexa, o que se verifica pela existência de um working group (WG) em UD dedicado especialmente a elas. A seguir, listamos as frases utilizadas no WG, traduzidas em português, e com a anotação adequada, além de algumas frases de anotação complexa no Bosque-UD.

1.1 Frases do Working Group

Figura 9: Eu coloquei tanta farinha quanto a receita pedia

Figura 10: Martin é o cara mais inteligente de todos

1.2 Frases do Bosque-UD

Abreviações

Ir para tabela de conteúdos

Agradecimentos

Ir para tabela de conteúdos

Referências

Bick, Eckhard. 2000. The parsing system Palavras. Automatic Grammatical Analysis of Portuguese in a Constraint Grammar Framework.

de Souza, Elvis & Cláudia Freitas. 2019. (Re)começando a discutir as locuções verbais. Em VI Jornada de Descrição do Português, STIL 2019.

McDonald, Ryan, Joakim Nivre, Yvonne Quirmbach-Brundage, Yoav Goldberg, Dipanjan Das, Kuzman Ganchev, Keith Hall, Slav Petrov, Hao Zhang, T Oscar et al. 2013. Universal dependency annotation for multilingual parsing. Em *Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, 92–97.

Rademaker, Alexandre, Fabricio Chalub, Livy Real, Cláudia Freitas, Eckhard Bick & Valeria de Paiva. 2017. Universal dependencies for Portuguese. Em Proceedings of the Fourth International Conference on Dependency Linguistics (Depling 2017), 197–206.